

Visão Computacional

Aula 09

Filtros Lineares
Bordas e Ruídos

Derivadas em Imagens

- Relembrando:


$$\frac{\partial f}{\partial x} = \lim_{\varepsilon \rightarrow 0} \left(\frac{f(x + \varepsilon, y)}{\varepsilon} - \frac{f(x, y)}{\varepsilon} \right)$$

- Observem que esta expressão é linear e invariante ao deslocamento, então pode ser o resultado de uma convolução.

- Podendo ser aproximada como:

$$\frac{\partial f}{\partial x} \approx \frac{f(x_{n+1}, y) - f(x_n, y)}{\Delta x}$$


Extraíndo as derivadas...




Ruído (*Noise*)

- Modelo simplificado do ruído:
 - Independente, estacionário com adição de ruído gaussiano;
 - O valor do ruído em cada pixel é dado pela obtenção de uma distribuição de probabilidade normal;
- Problemas:
 - Este modelo permite que valores de ruído podem ser maiores que a saída máxima (saturação no pixel) ou valores negativos de pixels;
 - Para pequenos desvios padrões, o modelo funciona bem;
 - A “independência” entre os valores de ruído podem não ser obtidas (ex.: danos físicos às lentes);
 - O ruído pode não ser estacionário (ex.: variações térmicas no sensores CCDs);

$\sigma=1$




$\sigma=16$



Diferenças Finitas (Derivadas) e Ruído

- Filtros Derivativos (Diferenças Finitas) tem respostas “intensas” ao ruído:
 - Razão óbvia: ruído em imagens resultam em pixels que diferem em muito dos pixels vizinhos;
- Geralmente, quanto maior o ruído, mas intensa a resposta do filtro.
- O que deve ser feito?
 - Intuitivamente, os pixels se parecem em muito com seus vizinhos;
 - Esse processo acontece mesmo nas regiões de bordas:
 - Ao longo da borda eles são semelhantes; através da borda não são;
 - Realizar filtragem de suavização geralmente ajuda, forçando pixels diferentes dos vizinhos a serem semelhantes;

Resposta de derivadas ao Ruído

[illegible]

A resposta de um filtro linear ao ruído

- Geralmente aplicado para situações de ruído não somente gaussiano de média zero.
- **Idéia básica:**
 - A saída é uma soma ponderada das entradas;
 - Variáveis aleatórias;
 - Média zero;
- **Variância:**
 - **Relembrando(propriedades):**
 - Variância de uma soma de variáveis aleatórias é a soma das suas variâncias;
 - Variância de uma constante x variável aleatória é constante (ao quadrado) x variância;
 - Então se σ é a variância do ruído e o Kernel é K , variância da resposta é dado por:


$$\sigma^2 \sum_{u,v} K_{u,v}^2$$

A resposta do filtro é correlacionada


- “Escala” semelhante a escala do filtro;
- Ruído Filtrado é usualmente aplicado em:
 - Simulação de texturas naturais,
 - ex.: simulação de fogo




Operando com um Kernel...



Operando com um Kernel...



Operando com um Kernel...






Suavização reduz o ruído

- Geralmente espera-se que os pixels seja semelhantes aos vizinhos:
 - Superfície varia lentamente;
 - Poucas mudanças na reflectância;
- Espera-se que os processos com ruídos sejam independente pixel a pixel.
- Implica que a suavização “suprime o ruído” com a utilização de modelos apropriados;
- Fator de Escala:
 - O parâmetro de uma Gaussiana simétrica;
 - O parâmetro aumenta e mais pixels são envolvidos;
 - Utiliza a média;
 - Aumenta o “borramento” da imagem;

$\sigma=0.05$

$\sigma=0.1$

$\sigma=0.2$



no
smoothing

Efeitos da suavização




$\sigma=1$ pixel



$\sigma=2$ pixels

Filtro de Suavização (Gaussiano)



n	2 ⁿ	Máscara de coeficientes
1	2	1 1
2	4	1 2 1
3	8	1 3 3 1
4	16	1 4 6 4 1
5	32	1 5 10 10 5 1
6	64	1 6 15 20 15 6 1
7	128	1 7 21 35 35 21 7 1
8	256	1 8 28 56 70 56 28 8 1

$$\frac{1}{64} \cdot \begin{bmatrix} 1 & 3 & 3 & 1 \\ 3 & 9 & 9 & 3 \\ 3 & 9 & 9 & 3 \\ 1 & 3 & 3 & 1 \end{bmatrix} \cdot \frac{1}{16} \cdot \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix} \cdot \frac{1}{256} \cdot \begin{bmatrix} 1 & 4 & 6 & 4 & 1 \\ 4 & 16 & 24 & 16 & 4 \\ 6 & 24 & 36 & 24 & 6 \\ 4 & 16 & 24 & 16 & 4 \\ 1 & 4 & 6 & 4 & 1 \end{bmatrix}$$

→ Triângulo de pascal para geração discreta da Gaussiana

Gradientes e Contornos/Bordas

- Pontos de variação de sombreamento nas imagens são interessantes, pois indicam:
 - Mudança na reflectância;
 - Mudança no objeto;
 - Mudança na iluminação;
 - Ruído;
- Algumas vezes são chamados de pontos de bordas (**edge points**)
- Estratégia Geral:
 - Determinar o gradiente da imagem;
 - Indica posições onde o gradiente (amplitude) é elevado (em relação à vizinhança de pixels);






Existem três maiores problemas:

- 1) O gradiente em diferentes resoluções são diferentes? Se sim, qual escolher?
- 2) A amplitude é grande em direção de “uma linha”, como identificar os pontos significantes?
- 3) Como “linkar” esses pontos com a curva?

Suavização e Diferenciação

- Problema: ruído
 - Suavizar antes de “diferenciar”(derivar)
 - Duas convolução para suavizar, então derivar?
 - Atualmente usa-se a derivada de um filtro gaussiano:
 - Utiliza-se a propriedade associativa da convolução






1 pixel

3 pixels

7 pixels

A escala da suavização afeta as estimativas das derivadas e também recuperação de bordas.



Queremos marcar pontos ao longo da curva onde a magnitude é maior.


Nós podemos fazer isso procurando por um máximo ao longo de uma fatia normal a curva (supressão não máxima). Esses pontos devem formar uma curva. Há duas questões algorítmicas: em que ponto é o máximo, e onde está o próximo máximo?



Atenção especial:

- Eventos desagradáveis acontecem nas “bordas”
- Escala afeta o contraste
- “Bordas” não são delimitadores de contornos





fine scale
high
threshold





coarse
scale,
high
threshold



coarse
scale
low
threshold


Filtros são “Templates”

- Aplicando um filtro em alguns pontos, estes podem ser “vistos” como o produto escalar entre uma imagem e algum vetor
- Filtragem em uma imagem é um conjunto de produtos escalares






Zero mean image, -1:1 scale




Positive responses

Zero mean image, -max:max scale






Zero mean image, -1:1 scale



Positive responses

Zero mean image, -max:max scale




O Laplaciano

- Um outra forma de detectar o maior valor da derivada de primeira ordem é utilizar a derivada de segunda ordem;
- Analogia: invariante à rotação
 - O Laplaciano!


Problemas/Avisos

- Necessita de suavização
 - Suavização Gaussiana em seguida Laplaciano
 - É a mesma idéia anterior utilizando o Laplaciano do Gaussiano




contrast=1


$\sigma=4$




contrast=4




$\sigma=2$






Filtro Laplaciano



0	1	0
1	-4	1
0	1	0

1	1	1
1	-8	1
1	1	1

- Filtro passa alta.
- Somar à imagem original para realçar os detalhes.





Próxima aula...

- Detecção de Bordas – Filtro de Canny